

KONVOLUCIJSKI REKURZIVNI MODELI ZA OZNAČAVANJE GLAZBE

KRISTIJAN BARTOL

ZADATAK - OZNAČAVANJE GLAZBENIM ŽANROVIMA

- primjeri žanrova: rock, pop, jazz, instrumental, electronic, spoken...
- jedna pjesma može pripadati u više žanrova multi-output classification
- problem s glazbom: ispravne oznake? (ground truth)



INTERPRETACIJA ZVUKA

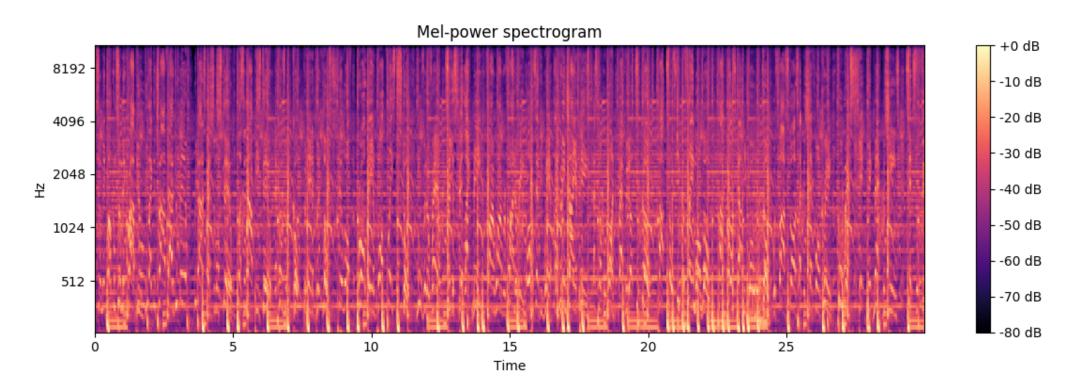


1 Second

https://deepmind.com/blog/waven et-generative-model-raw-audio/



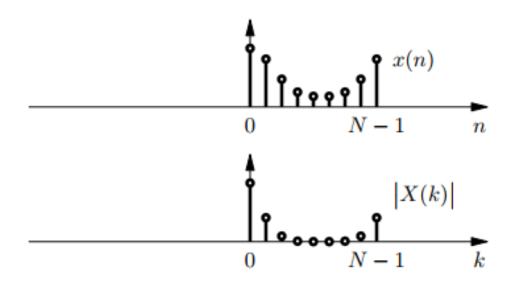
EKSTRAKCIJA (BITNIH) ZNAČAJKI - MEL-SPEKTROGRAMI





EKSTRAKCIJA BITNIH ZNAČAJKI - MEL-SPEKTROGRAMI

DFT



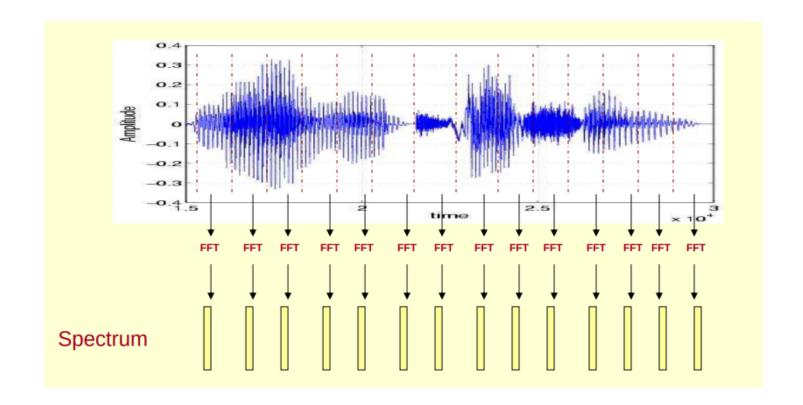
$$X_k = x_0 e^{-jW_N^{k0}} + x_1 e^{-jW_N^{k1}} + \dots + x_n e^{-jW_N^{kn}}$$

$$x(n) = \frac{1}{N} \sum_{k=0}^{N-1} X(k) W_N^{-kn}, \quad 0 \le n \le N-1$$

$$X(k) = \sum_{n=0}^{N-1} x(n) W_N^{kn}, \quad 0 \le k \le N-1$$

$$W_N^{nk} = e^{-2\pi j nk/N}$$

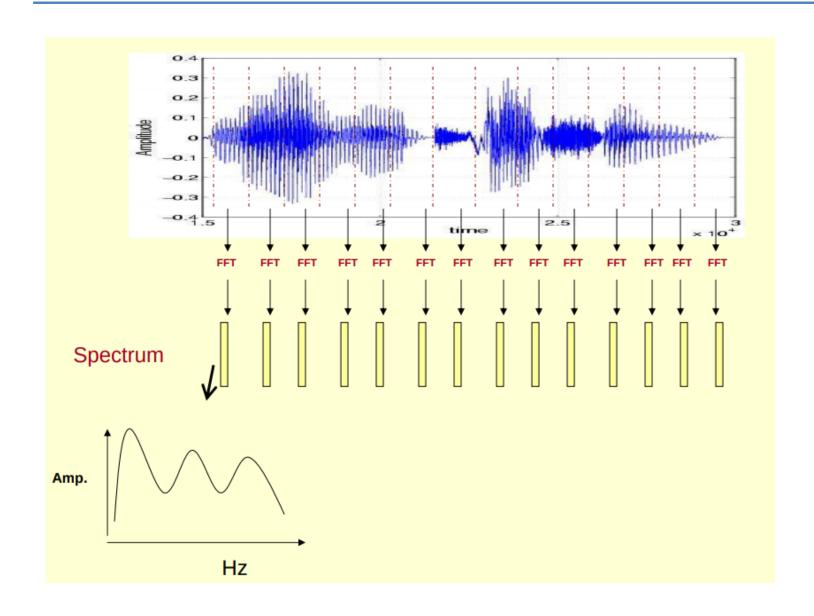




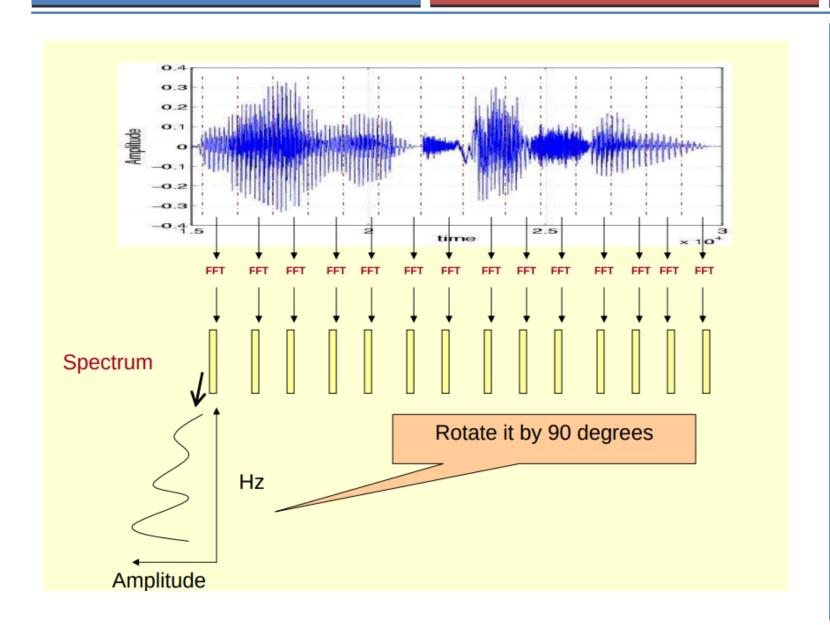
FFT = optimizirani DFT

EKSTRAKCIJA (BITNIH) ZNAČAJKI

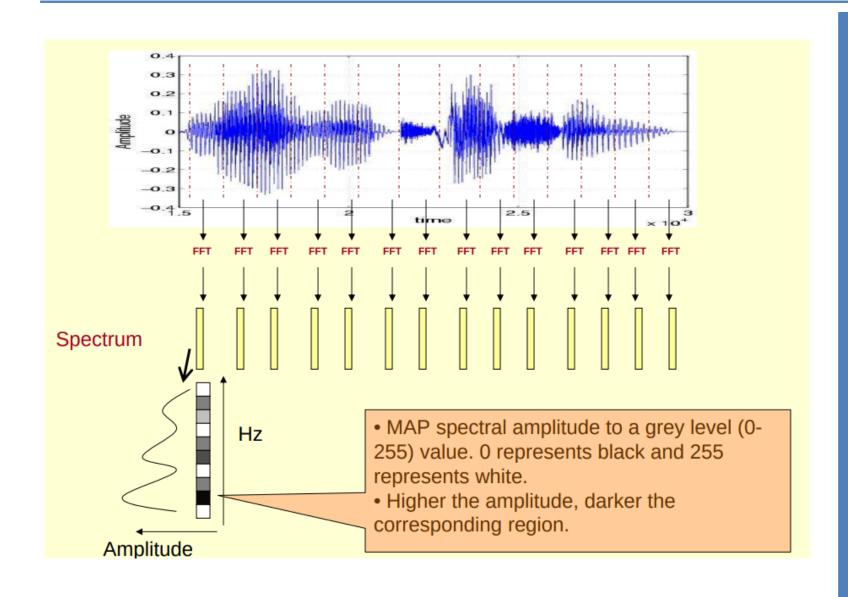




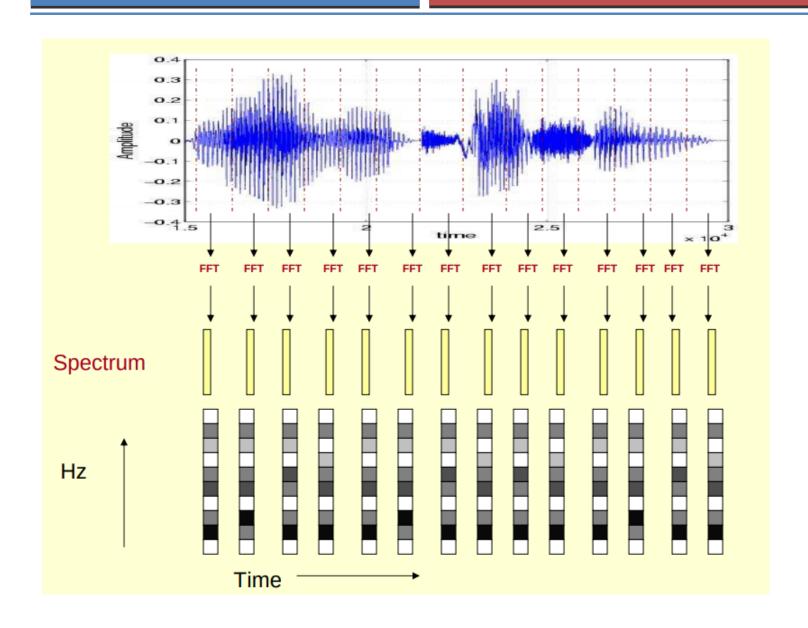














ZAŠTO "MEL"?

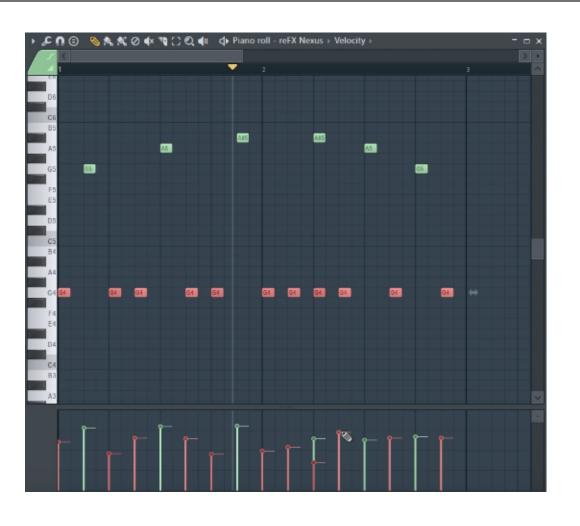
- melodijska skala ljudima prirodnija
- nelinearna skala moguća pretvorba u točnu vrijednost frekvencije i obrnuto

$$M(f) = 1125 \ln(1 + f/700)$$

$$M^{-1}(m) = 700(\exp(m/1125) - 1)$$

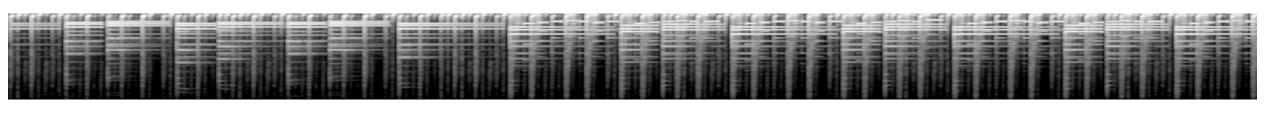


MEL-SPEKTROGRAMI – INTUICIJA?

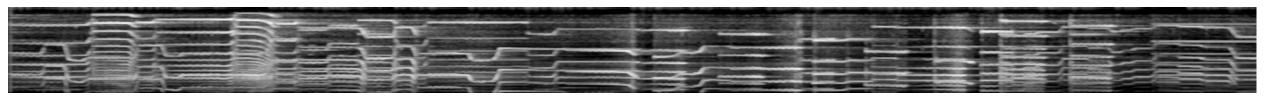




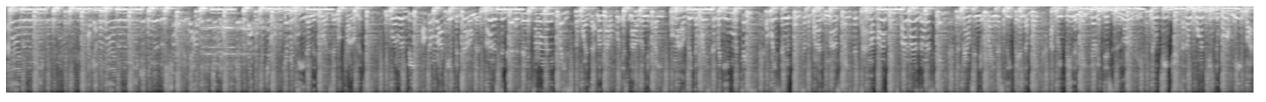
PRIMJERI IZRAČUNATIH SPEKTROGRAMA



Electronic

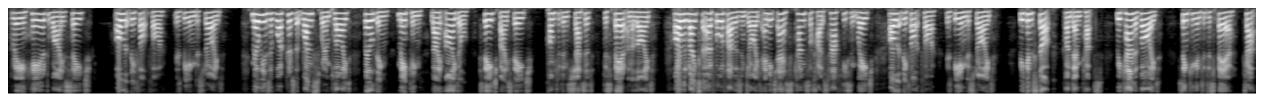


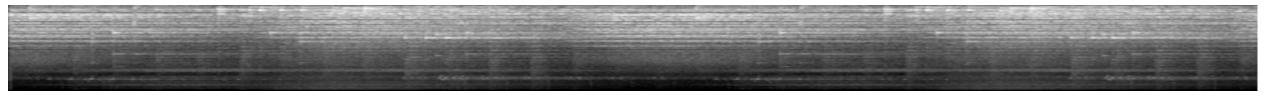
Experimental

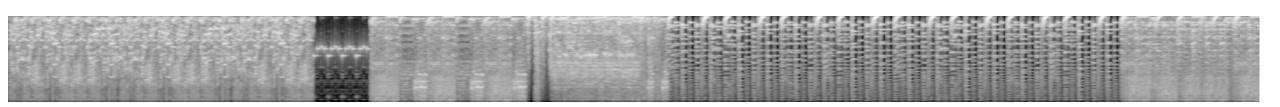




PRIMJERI IZRAČUNATIH SPEKTROGRAMA

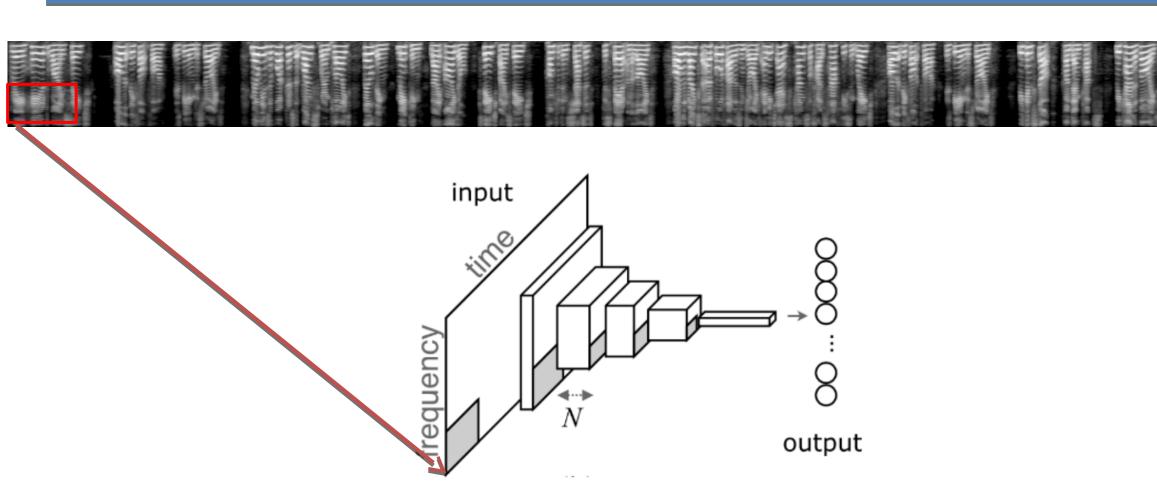








KONVOLUCIJSKA ARHITEKTURA - INSPIRACIJA IZ PODRUČJA SLIKE

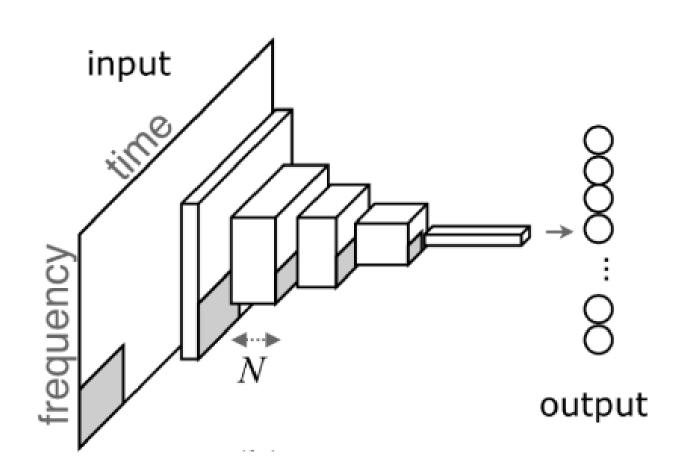




KONVOLUCIJSKA ARHITEKTURA

- sakuplja lokalne značajke spektrograma (!)
- spektrogrami često imaju harmonijske korelacije; ne toliko lokalne [1]

[1] https://arxiv.org/pdf/170 9.04396.pdf

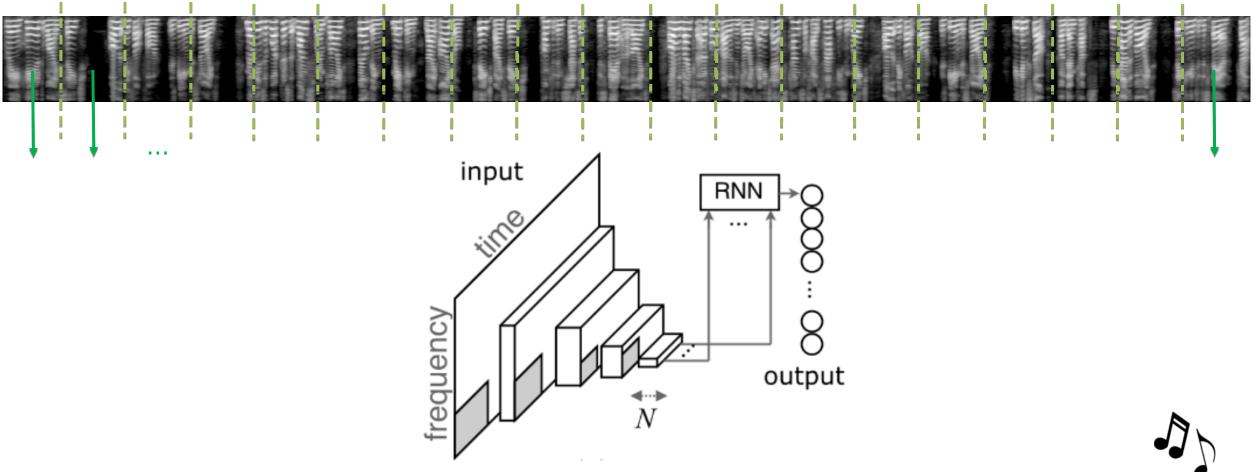








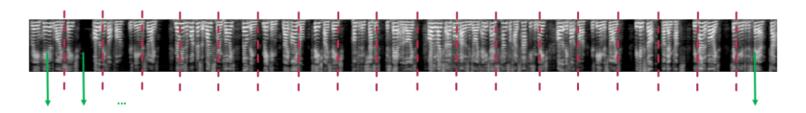
KONVOLUCIJSKA REKURZIVNA ARHITEKTURA

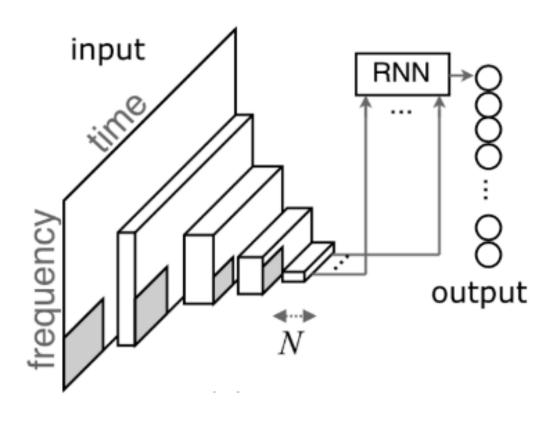


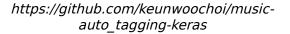


KONVOLUCIJSKA REKURZIVNA ARHITEKTURA

- razdvaja uzorak u sekvence što intuitivno više odgovara prirodi glazbe
- sakuplja globalne značajke spektrograma nakon konvolucijskih slojeva



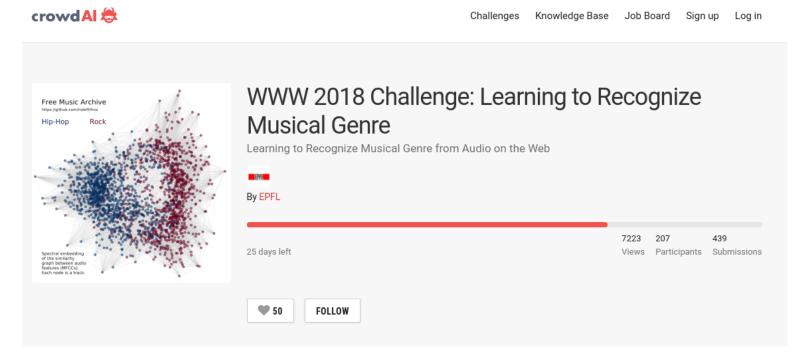






RADI LI U PRAKSI?

- proradilo jučer!
- treba ponovno pokušati trenirati nad čitavim skupom za učenje i minimizirati gubitak unakrsne entropije

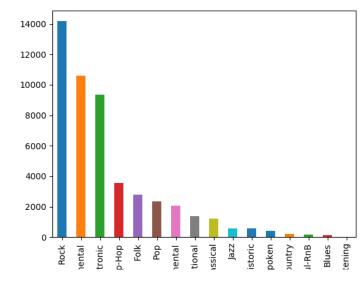


https://www.crowdai.org/challenges/www-2018-challenge-learning-to-recognizemusical-genre



KORIŠTENI DATASET – FMA

- Free Music Archive, FMA (Github)
- većina pjesama pod CC licencom
- ukupno 161 klasa



	Broj pjesama	Trajanje	Veličina
Mali	8000	30s	7.2GiB
Srednji	25.000	30s	22GiB
Veliki	105.574	30s	93GiB
Potpuni	105.574	Cijela pjesma	879GiB



OSTALI GLAZBENI DATASETI

glavni problemi: licenca, mali broj primjera, skupovi bez audio primjera

	Broj pjesama	Različitih oznaka	Dostupan audio
GTZAN	1000	10	da
MSD	1000000	522.366	ne
Vlastiti dataset?	neograničeno	npr. 161	da*



"DEBUGGIRANJE" MREŽE

- odakle početi? npr. 37 Reasons why your Neural Network is not working
- mogući razni problemi s podacima (Učitavaju li se dobro? Pravilno pridružene izlazne oznake? Skup dovoljno velik?)
- moguće implementacijske pogreške (Uči li se dobra funkcija pogreške? Buggovi?)
- model nedovoljnog kapaciteta, nedovoljno vremena za učenje, itd...



ZAKLJUČAK

- problem je težak
- uspješna multi-output klasifikacija značila bi uspješnu ekstrakciju bitnih značajki



DALJNJE MOGUĆNOSTI

- nenadzirano grupiranje prema stilu / razdoblju / drugim apstraktnijim značajkama
- generiranje nove glazbe mogućnost specifikacije žanra / stila / razdoblja
- umjetna kreativnost u glazbi

